Последовательные рекомендации: RL, повторы и качество reward

Ислам / Islam-Y · 15 октября 2026
github.com/Islam-Y/RecSys-RL

Задание 2 T-Lab 2026. Итог исследования на 15 октября 2026.

1. Что проверено и получено

Обучены GPT-2 для следующего трека и модель вознаграждения; выполнено RL-дообучение, исследованы функции reward, KL-регуляризация и генерация пяти объектов. Дополнительно проверены смешанная цель RL/CE, явный учёт повторов и reward model с историей откликов.

Главный вывод: повысить прогнозируемое вознаграждение возможно, но это не гарантирует более полезных рекомендаций. Найдены положительные офлайн-эффекты для baseline и прогноза доли прослушивания; улучшение пользовательского опыта или преимущество RL над сильными контролями не установлено.

Серия	Результат	Граница вывода
Исходная RL, original final test	Hybrid reward +1.99%; NDCG@10 -2.55%	Прирост прокси с потерей релевантности по точечной оценке
Явный учёт повторов, новая популяция	NDCG@10 +23.73%; Recall@10 +26.55% против GPT-2	Победа над recent-items не подтверждена
История откликов, новые development-пользователи	MSE 0.19679 → 0.12524 против прежнего hybrid	Выбор кандидатов остаётся слабым; новая RL-серия не допущена

Строки относятся к разным оценочным группам. Их абсолютные метрики нельзя сравнивать как последовательный рост качества; каждый прирост рассчитан внутри своей группы.

Продуктовая постановка

Цель - рекомендации, которые нравятся пользователю и поддерживают возвращение. Доступная доля прослушивания служит косвенным сигналом: человек может дослушать трек без удовлетворения или прервать понравившийся по внешней причине. Рост времени, числа повторов или прогнозируемого reward не приравнивается к пользе.

Положительный эффект RL не обязателен по условию задания. В этой работе исследованы работающий алгоритм, поведение и причины ограничений; отрицательные результаты сохранены вместе с положительными.

2. Данные, модели и протокол

Источник - Yambda-50M, 46 467 212 listen-событий. Первая популяция - 1 000 пользователей по ранней активности; каталог - 2 000 наиболее частых train-треков. Границы: train до 19 983 235 секунд, validation до 23 121 935, test до 26 000 000.

Исходная выборка	Запросы	Пользователи	Уникальные цели внутри запросов
Train	59 888	961	68 451
Validation	5 000	734	5 840
Final test	5 000	755	5 793

Контекст - BOS и максимум 64 listen-события строго до T. Все события текущего user/T исключаются из истории; цели оцениваются множеством. История в test включает реальные прошлые test-события без обновления весов. Вне каталога - UNK: 61.77% событий train-контекстов. Каталог покрывает 19.87% listen-событий original test. Выводы условны на попадание цели в каталог.

Ранжируются все 2 000 объектов, без сэмплирования негативов. Recall@K измеряет долю целей в выдаче, NDCG@K учитывает позиции. K = 5/10/20; основной ranking-критерий NDCG@10, равный вес запросов.

GPT-2: ID-токены, случайная инициализация, два слоя, ширина 128, четыре головы, 661 504 параметра. Проверены три размера и восемь рецептов маленькой модели. Выбран lr 0.0001, dropout 0.1, wd 0.01; reference seed 42, эпоха 26. Рецепт подтверждён seeds 42/43/44 на адаптивной validation.

Исходная reward model: embeddings/MLP, 202 593 параметра; история, кандидат, user ID, длительность и признаки повторов. Метка - среднее min(played_ratio_pct,100)/100 по наблюдавшимся дубликатам user/T/item. Нули сохраняются; непрослушанные кандидаты не получают вымышленные нули. Ранний reward train: 54 412 пар; поздняя selection: 14 039. Checkpoint по selection MSE.

На original test MSE raw 0.18133, hybrid 0.17121, персонального среднего 0.17564; MAE hybrid хуже среднего: 0.36546 против 0.35590. Query-macro accuracy кандидатов с разными долями - 53.05% у raw против 55.96% у средней по треку. Улучшение регрессии не установило преимущества в выборе кандидатов.

Код, конфигурации и критерии каждой новой серии записывались до запусков. Для последующего подбора открытые test не считаются независимыми. Новые группы исключают полные прежние популяции, включая пользователей без оценочных запросов. Интервалы - user-cluster bootstrap, 2 000 повторов; веса запросов, наблюдавшихся пар и парных сравнений различаются и указаны отдельно.

3. RL: вознаграждение и релевантность

Одношаговый модельный контекстный бандит:

J = mean_h [sum_i pi(i|h)*r(h,i) - beta*KL(pi||pi_ref)].

Обучаются веса GPT-2; reward model/reference фиксированы. Точная сумма по каталогу даёт прямой градиент ожидания. Реальные переходы пользователя и многошаговый return не обучаются. Пять эпох на одинаковых 4 000 поздних train-контекстах, AdamW lr 0.00005, batch 64, clip 1, dropout выключен, последняя эпоха.

Проверены raw, hybrid и time reward, разные KL и стресс-контроль без KL. Hybrid - фиксированная калибровка raw со средним по пользователю. Он имеет вид 0.3565745*raw + constant(user): улучшение регрессии не создаёт нового порядка кандидатов. При согласованном масштабе KL аналитические raw/hybrid политики совпали с погрешностью 1.48e-7.

Выбор по validation: максимальный hybrid top-10 при NDCG минимум 95% reference, исключая стресс-контроль. Raw с KL = 0.1 подтверждён seeds 42/43/44; всего восемь обучений. Final test открыт после фиксации выбора. KL = 1 заранее задан как дополнительное сравнение.

Original final test	NDCG@10	Recall@10	Hybrid top-10
GPT-2	0.09121	0.14119	0.64693
Выбранная RL, KL = 0.1	0.08889	0.14153	**0.65979**
Дополнительная RL, KL = 1	0.09137	0.14146	0.64871
Недавние треки + популярность	**0.10026**	**0.15626**	0.65237

Выбранная RL: reward +1.99%, NDCG -2.55%. Интервал разницы NDCG [-0.004946; +0.000226] включает ноль - эквивалентность не доказана. Сильный KL: reward +0.28%, NDCG +0.18% по точечной оценке, также без подтверждённого прироста релевантности. Reward списка отличается от ожидаемого reward всей softmax-политики.

Без KL на validation NDCG упал на 61.85%, десять самых выдаваемых объектов заняли 72.91% top-10 выдачи против 7.34% baseline. Time reward вырос на 23.62%, но NDCG снизился на 11.51%, средняя длительность рекомендаций выросла с 191 до 246 секунд.

Смешивание RL с supervised CE проверено отдельной серией: три веса CE, ещё три контроля, по пять эпох. Все смешанные варианты потеряли 3.19-3.60% NDCG при допуске 1%; не приняты. Уменьшение sampled-повторов не компенсировало потерю релевантности.

4. Явный учёт повторов и контроль обучения

Сильный recent-items baseline указал на резерв качества. Добавлена смесь:

p = (1-g)*p_GPT2 + g*q_recent.

q суммирует exp(-lag/tau) по появлениям треков в истории. Lag измеряется событиями, включая UNK, не днями. Без известных объектов g = 0. Идея повторного потребления близка RepeatNet; его архитектура не воспроизводилась.

Шесть вариантов: глобальная/контекстная доля и tau 1/4/16. GPT-2 заморожена; gate обучается CE на всех 59 888 train-запросах. Выбран global-16: один обучаемый параметр, g = 0.1080394. Он прошёл development-пороги на seeds 42/43/44. Более сложный 161-параметровый gate уступил глобальному.

Новая группа: 1 000 пользователей вне двух прежних популяций, 5 000 запросов от 753 пользователей. Выбор смеси записан до прогнозов на этой группе.

Новая recency-популяция	NDCG@10	Recall@10
GPT-2	0.08190	0.12501
Недавние треки + популярность	0.09983	0.15547
GPT-2 + recency	**0.10133**	**0.15820**

Против GPT-2: NDCG +23.73%, Recall +26.55%; интервалы разниц [0.01559; 0.02333] и [0.02653; 0.04001] выше нуля. Против recent-items NDCG +1.51%, но интервал [-0.00246; 0.00545] включает ноль. Строгий критерий победы над обоими контролями не выполнен.

На 946 запросах со всеми целями в истории NDCG GPT-2 → смесь: 0.33027 → 0.45154. На остальных 4 054 запросах, с хотя бы одной новой для истории целью: 0.02394 → 0.01961. Усиление повторов ухудшило второй срез.

Нужна ли обученная доля

После открытия recency-популяции отдельно проверены заранее фиксированные доли при том же tau = 16:

Доля recency	Validation NDCG	Открытая recency-группа NDCG
Обученная, 10.804%	0.11571	0.10133
Фиксированная, 10%	0.11524	0.10018
Начальная sigmoid(-2), 11.920%	0.11658	0.10161

Это последующая диагностика, не независимый test. Фиксированная начальная доля дала не меньшую точечную оценку; полезность обучения доли не установлена. Основной наблюдаемый прирост связан с добавлением recency-механизма. Победитель задним числом не заменён; in-sample logits GPT-2 при обучении gate остаются ограничением.

5. История откликов улучшает MSE, но не выбор кандидата

Reward model расширена строго прошлыми наблюдавшимися откликами: средние доли пользователя, короткие окна, прошлые отклики на кандидата, число/давность появлений, длительность и сглаженный item prior. User ID не требуется. История откликов - последние 64 distinct user/T/item события, дубликаты усреднены; все события текущего T исключены. Для train item prior применяется leave-one-out, для последующих периодов - только ранний train.

Три рецепта: линейная поправка (17 параметров), MLP с embeddings (39 345), тот же MLP с 0.05 pairwise loss. Pair loss использует наблюдавшихся кандидатов одного user/T: 9 014 обучающих сравнений, без искусственных негативных меток. Максимум 12 эпох, patience 4, checkpoint по прежней selection MSE. Линейный вариант выбрал эпоху 12, оба MLP - эпоху 1.

Новая development-группа: 500 пользователей вне трёх прежних популяций; 5 000 запросов от 383 пользователей, 5 868 наблюдавшихся пар. Метки открыты после фиксации трёх checkpoint. Эта группа участвует в выборе рецепта и не является final test.

Метод	Development MSE	MAE	Query-macro pair accuracy, gap >= 0.10
Исходная raw reward model	0.20271	0.41452	42.83%
Прежний hybrid	0.19679	0.41915	42.83%
Средняя прошлых откликов пользователя	0.14341	0.30699	50.00%
История + линейная поправка	0.12557	0.28508	43.91%
История + MLP	**0.12524**	0.27921	44.20%
История + pairwise MLP	0.12840	**0.27703**	47.58%

Лучший MSE ниже hybrid на 36.36%, прошлого персонального среднего - на 12.67%. Интервал MSE-разницы MLP с персональной историей [-0.02192; -0.01446] ниже нуля. Это описательный development-результат; состав входной истории расширен, поэтому эффект не приписывается только архитектуре.

Для различения кандидатов доступны 1 863 сравнения из 120 запросов, 81 пользователь. Query-macro accuracy pairwise MLP 47.58% [39.48%; 55.34%]; сглаженный item prior 44.38%, простой prior прошлого отклика на кандидата 53.22%. Интервалы включают 50%; уверенное различение не установлено. При взвешивании пар, а не запросов, оценки меняются.

Решение по протоколу: ни одна модель не прошла порог query-macro accuracy 55%. Улучшение MSE и остальные проверки не заменяют этот критерий. Новая RL-серия не запущена; отдельный final reserve из 1 000 пользователей, 5 000 запросов, 739 query-пользователей остался без прогнозов и response-меток.

Интерпретация: модель лучше определяет общий стиль прослушивания пользователя. Но для ранжирования важна разница между кандидатами одной истории. Улучшение общей ошибки не гарантирует улучшения этой разницы.

6. Пять шагов, долгосрочная цель и воспроизведение

Rollout: общие 1 000 validation-историй, пять последовательных ID с добавлением в контекст. Рекомендация не означает фактическое прослушивание; будущим шагам не присваивались вымышленные наблюдавшиеся метки.

Политика, sampled	Уникальных из 5	Повтор предыдущего на шаге 5
GPT-2	4.253	16.6%
Исходная RL, KL = 0.1	4.024	25.2%
Исходная RL без KL	1.169	96.2%
GPT-2 + recency	4.121	17.1%

Greedy почти зацикливается уже у GPT-2: 1.027 уникального трека. Recency этот эффект не устраняет. Рост reward на синтетических историях не доказывает качества реальной последовательности.

Долгосрочная цель

Возможные метки: продолжение сессии в пределах 30 минут, возвращение от 24 часов до семи суток. Нулевая метка допустима лишь при полностью наблюдаемом будущем окне; примеры у правой границы данных цензурируются. Офлайн можно проверить предсказуемость, калибровку и устойчивость по времени/пользователям. Причинный вклад рекомендаций потребует данных показов и онлайн-проверки вместе с негативными реакциями/явной оценкой. Модель удержания здесь не обучалась.

Ограничения и аудит

Один источник, ограниченный каталог, высокая доля UNK и адаптивная validation. Новые популяции того же источника/периода не заменяют независимый датасет. Reward основан на наблюдавшихся прослушиваниях; отклик на произвольный новый показ неизвестен. Bootstrap не учитывает всю неопределённость обучения reward model. Включение нуля в интервал не доказывает эквивалентности.

Аудиты повторили forwards, метрики, выбор, SHA, raw-подготовку новых когорт и response-историй; максимальные расхождения проверенных forwards - 0. Последняя серия: подготовка 5.34 с, три обучения с оценкой 37.49 с, аудит 16.78 с на Apple M4/MPS. Автоматические тесты не добавлялись.

Python 3.14.7; PyTorch 2.14.1, Transformers 5.19.0, NumPy 2.5.4, DuckDB 1.5.6. Данные/веса локальны; агрегированные результаты и код опубликованы. Команды и версии кода по этапам - в README. Исторические аудиты требуют записанного source commit и соответствующих локальных артефактов. Подробные протоколы/результаты: RL, original test, смешанная цель, recency, история откликов, последний аудит.

Итог: работающий RL-эксперимент выявил компромисс reward/релевантности и коллапс без KL. Явный учёт повторов улучшил baseline, история откликов улучшила регрессию reward. Слабая переносимость выбора кандидатов ограничила следующий RL-этап; положительный пользовательский эффект не заявляется.