Смешанная цель RL и next-item

Ислам / Islam-Y · 15 октября 2026
github.com/Islam-Y/RecSys-RL

1. Гипотеза и результат отбора

Проверена гипотеза: next-item loss во время RL уменьшит потерю релевантности. **Смешанный checkpoint не принят:** три варианта потеряли 3.19-3.60% validation NDCG при допуске 1%. Первая серия и её PDF сохранены.

Код, протокол и конфигурация зафиксированы до подготовки новой выборки и обучения: 101920acd117358b0105980bdcb62a85cb1a473d.

Цель: L = -w_reward*E_pi[p] + beta*KL(pi||pi_ref) + gamma*CE. Уникальные next-item цели усредняются внутри запроса. Все варианты начинают с одного reference seed 42, эпоха 26; используют прежние 4 000 поздних train-историй и frozen reward-кэш.

Пять эпох, последняя эпоха без early stopping; AdamW learning rate 0.00005, batch 64, weight decay 0, clip norm 1, dropout выключен. Reward model и калибровка не меняются. Идея смешивания мотивирована Ouyang et al., PPO-ptx; её перенос в рекомендации проверяется отдельно.

Вариант, seed 42	gamma	beta	NDCG@10	Hybrid reward
Reference	-	-	0.10275	0.64978
RL-only	0	0.1	0.09925	0.66220
Strong KL	0	1	0.10271	0.65148
Next-item-only	1	0	0.09557	0.64952
Mixed-001	0.001	0.1	0.09905	0.66206
Mixed-01	0.01	0.1	0.09940	0.66004
Mixed-1	0.1	0.1	0.09947	0.65274

Next-item-only выключает reward-часть и контролирует эффект дополнительных supervised-эпох. Hybrid reward - средний прогноз top-10, не ожидание полной softmax-политики.

Для отбора требовались NDCG >= 99% максимума reference/next-item-only, рост hybrid относительно reference/strong KL/next-item-only, ограничения охвата, концентрации и sampled-повторов. Никто не прошёл NDCG-порог; сохранён baseline. Seeds 43/44 по правилу не запускались: выполнено шесть обучений из максимальных десяти.

Поведение и обучение

Выполнены 14 rollout на 1 000 validation-историй. Gamma 0.1 уменьшил sampled-повтор на шаге 5 с 25.2% у RL-only до 17.7%; уникальных объектов стало 4.281 вместо 4.024. Это улучшение синтетической генерации сопровождалось недостаточным NDCG.

2. Проверка на ранее не использованных пользователях

До обучения выбраны 1 000 пользователей Yambda с >= 50 train-прослушиваниями. Полная исходная популяция из 1 000 пользователей исключена; пересечение равно нулю. Выбор по ранней активности и фиксированному hash seed 20261015. Доли прослушивания при подготовке не читались.

Новая выборка: 5 000 запросов от 751 пользователя, 5 694 цели, прежний каталог 2 000 треков. Период 23121935 < T <= 26000000; история BOS и последние 64 события строго раньше T. Target ID подготовлены заранее, но модели не оценивались на них до фиксации решения. Фактические доли присоединены после записи выбора и SHA checkpoint.

Смешанные модели на новый holdout не допущены. По плану оценены заранее заданные контроли. Новые пользователи неизвестны user-embedding reward model, используется прежний fallback без адаптации. Абсолютные метрики другой популяции нельзя сравнивать с прежним test как измерение прироста; ниже показано парное сравнение внутри новой выборки.

Политика	NDCG@10	Recall@10	Hybrid reward
Reference	0.07980	0.12498	0.64150
RL-only, beta 0.1	0.07849	0.12276	**0.65792**
Strong KL, beta 1	0.08015	0.12583	0.64382
Next-item-only	0.07549	0.11809	0.64106
Train-популярность	0.01215	0.02429	0.64410
Недавние + популярность	**0.10215**	**0.15727**	0.64768

Strong KL повысил hybrid reward на 0.36%, NDCG - на 0.44% по точечной оценке. User-cluster 95%-интервал разницы NDCG [-0.000355; +0.001088] включает ноль; интервал hybrid [+0.002204; +0.002442]. Это описательное дополнительное сравнение. Основное подтверждение смешанного кандидата не проводилось, поскольку допустимого кандидата не было.

Next-item-only потерял 5.40% NDCG относительно reference; интервал разницы [-0.006885; -0.001771]. Контроль недавних треков выше reference на 28.00% по NDCG в этой популяции. Контроль недавних треков подтверждает резерв качества базовой политики.

Ограничение reward на новых пользователях

Raw reward model MSE = 0.19637, global/user-mean fallback = 0.19368, hybrid = 0.19238. Pearson raw = 0.08187. Пользовательская средняя здесь совпадает с глобальной: все пользователи новые. Прогноз reward не объявляется откликом на произвольный показ. Сдвиг популяции и слабый сигнал кандидата ограничивают смысл оптимизации такого прокси.

Веса, коэффициенты, каталог и выбор по новому holdout не изменялись. Bootstrap: 2 000 повторов пользователей, seed 42, равный вес запросов. Интервалы контролей описательные, без коррекции множественных сравнений; неопределённость reward model ими не измеряется. Удовлетворённость и причинное удержание не оценены.

3. Воспроизведение и вывод

Новые данные: data/processed/mixed-holdout-v1/. Обучения, rollout, выбор и оценка: outputs/mixed-objective-v1/. Все новые артефакты отделены от первой серии; исходный test повторно не оценивался. Перед запуском следующей идеи понадобится новая ещё не использованная оценочная популяция.

```
python -m recsys_rl.mixed_experiment --device auto --prepare-only
python -m recsys_rl.mixed_experiment --device auto --resume
python -m recsys_rl.mixed_experiment --device auto --audit
```

Нужны локальные данные, reward-кэш и checkpoints первой серии с указанными хешами. Непустые каталоги не перезаписываются; --resume допускает только неизменный план. Для повторения текущего результата используется --audit. Подробности среды и предыдущих этапов - в README.

Этап	Полное время
Подготовка новой популяции	3.54 с
Шесть обучений, rollout и итоговая оценка	164.50 с
Отдельный аудит	41.38 с

Apple M4/MPS, Python 3.14.7, PyTorch 2.14.1. Сумма внутреннего времени шести запусков - 108.64 с. Процесс серии: максимум RSS 1.53 ГиБ, peak memory footprint 2.76 ГиБ по macOS. Отдельный полный пик MPS/системы не измерялся.

Аудит повторил validation-forward шести сохранённых политик, все действия/reward 14 rollout, выбор, непересечение пользователей, присоединение новых response-меток, forward политик/reward и пересчёт метрик. Проверены хеши исходных моделей, кода и данных.

Опубликованы точные копии результата серии и нового holdout, подготовка, ресурсы и аудит. История решения - в журнале; первый итоговый отчёт сохраняет прежние результаты.

Next-item-only снизил train CE с 4.91443 до 4.02471, но validation CE вырос с 6.56984 до 6.67439, NDCG упал на 6.99%. Картина согласуется с переобучением/адаптацией к малому поднабору; причина не изолирована. CE рассчитан после серии и не управлял выбором.

Вывод. Проверенный рецепт смешивания уменьшил повторы относительно чистого RL, но не выполнил критерий релевантности. Новый смешанный checkpoint не принят. Контроль дополнительных supervised-эпох тоже ухудшился, поэтому проблема не сводится к отсутствию supervised loss. Общая бесполезность смешанного обучения этим экспериментом не доказана: проверены три gamma, один beta, пять эпох на 4 000 историях и один seed на этапе отбора.

Следующие обоснованные направления - усиление зависимого от кандидата reward-сигнала и включение явной давности прослушиваний в базовую политику. Они требуют отдельного протокола и независимой проверки.