Последовательные рекомендации: RL, повторы и качество reward

Ислам / Islam-Y · 15 октября 2026
github.com/Islam-Y/RecSys-RL

Задание 2 T-Lab 2026. Сводный отчёт исследования на 15 октября 2026. Включает расширение ранжирующего сигнала и повторную RL-серию.

1. Что проверено и получено

Обучены GPT-2 для следующего трека и модель вознаграждения; выполнено RL-дообучение, исследованы функции reward, KL-регуляризация и генерация пяти объектов. Дополнительно проверены смешанная цель RL/CE, учёт повторов, история откликов, парное обучение ранжировщика и повторный RL.

Главный вывод: повысить прогнозируемое вознаграждение возможно, но это не гарантирует более полезных рекомендаций. Подтверждены положительные офлайн-эффекты для baseline и выбора наблюдавшихся кандидатов; улучшение пользовательского опыта или преимущество RL над сильными контролями не установлено.

Серия	Результат	Граница вывода
Исходная RL, original final test	Hybrid reward +1.99%; NDCG@10 -2.55%	Прирост прокси с потерей релевантности по точечной оценке
Явный учёт повторов, новая популяция	NDCG@10 +23.73%; Recall@10 +26.55% против GPT-2	Победа над recent-items не подтверждена
История откликов, новые development-пользователи	MSE 0.19679 → 0.12524 против прежнего hybrid	Этот reward не прошёл допуск к RL
Ранжировщик, независимая confirmation-группа	Accuracy 58.42% против 53.52%; +4.90 п.п.	Подтверждено на наблюдавшихся парах, не на произвольных показах
Повторный RL, новый final reserve	Calibrated reward +0.30%; NDCG -0.56%	Сохранение NDCG в пределах 1% не подтверждено

Строки относятся к разным оценочным группам. Их абсолютные метрики нельзя сравнивать как последовательный рост качества; каждый прирост рассчитан внутри своей группы.

Продуктовая постановка

Цель - рекомендации, которые нравятся пользователю и поддерживают возвращение. Доступная доля прослушивания служит косвенным сигналом: человек может дослушать трек без удовлетворения или прервать понравившийся по внешней причине. Рост времени, числа повторов или прогнозируемого reward не приравнивается к пользе.

Положительный эффект RL не обязателен по условию задания. В этой работе исследованы работающий алгоритм, поведение и причины ограничений; отрицательные результаты сохранены вместе с положительными.

2. Данные, модели и протокол

Источник - Yambda-50M, 46 467 212 listen-событий. Первая популяция - 1 000 пользователей по ранней активности; каталог - 2 000 наиболее частых train-треков. Границы: train до 19 983 235 секунд, validation до 23 121 935, test до 26 000 000.

Исходная выборка	Запросы	Пользователи	Уникальные цели внутри запросов
Train	59 888	961	68 451
Validation	5 000	734	5 840
Final test	5 000	755	5 793

Контекст - BOS и максимум 64 listen-события строго до T. Все события текущего user/T исключаются из истории; цели оцениваются множеством. История в test включает реальные прошлые test-события без обновления весов. Вне каталога - UNK: 61.77% событий train-контекстов. Каталог покрывает 19.87% listen-событий original test. Выводы условны на попадание цели в каталог.

Ранжируются все 2 000 объектов, без сэмплирования негативов. Recall@K измеряет долю целей в выдаче, NDCG@K учитывает позиции. K = 5/10/20; основной ranking-критерий NDCG@10, равный вес запросов.

GPT-2: ID-токены, случайная инициализация, два слоя, ширина 128, четыре головы, 661 504 параметра. Проверены три размера и восемь рецептов маленькой модели. Выбран lr 0.0001, dropout 0.1, wd 0.01; reference seed 42, эпоха 26. Рецепт подтверждён seeds 42/43/44 на адаптивной validation.

Исходная reward model: embeddings/MLP, 202 593 параметра; история, кандидат, user ID, длительность и признаки повторов. Метка - среднее min(played_ratio_pct,100)/100 по наблюдавшимся дубликатам user/T/item. Нули сохраняются; непрослушанные кандидаты не получают вымышленные нули. Ранний reward train: 54 412 пар; поздняя selection: 14 039. Checkpoint по selection MSE.

На original test MSE raw 0.18133, hybrid 0.17121, персонального среднего 0.17564; MAE hybrid хуже среднего: 0.36546 против 0.35590. Query-macro accuracy кандидатов с разными долями - 53.05% у raw против 55.96% у средней по треку. Улучшение регрессии не установило преимущества в выборе кандидатов.

Код, конфигурации и критерии каждой новой серии записывались до запусков. Для последующего подбора открытые test не считаются независимыми. Новые группы исключают полные прежние популяции, включая пользователей без оценочных запросов. Интервалы - user-cluster bootstrap, 2 000 повторов; веса запросов, наблюдавшихся пар и парных сравнений различаются и указаны отдельно.

3. RL: вознаграждение и релевантность

Одношаговый модельный контекстный бандит:

J = mean_h [sum_i pi(i|h)*r(h,i) - beta*KL(pi||pi_ref)].

Обучаются веса GPT-2; reward model/reference фиксированы. Точная сумма по каталогу даёт прямой градиент ожидания. Реальные переходы пользователя и многошаговый return не обучаются. Пять эпох на одинаковых 4 000 поздних train-контекстах, AdamW lr 0.00005, batch 64, clip 1, dropout выключен, последняя эпоха.

Проверены raw, hybrid и time reward, разные KL и стресс-контроль без KL. Hybrid - фиксированная калибровка raw со средним по пользователю. Он имеет вид 0.3565745*raw + constant(user): улучшение регрессии не создаёт нового порядка кандидатов. При согласованном масштабе KL аналитические raw/hybrid политики совпали с погрешностью 1.48e-7.

Выбор по validation: максимальный hybrid top-10 при NDCG минимум 95% reference, исключая стресс-контроль. Raw с KL = 0.1 подтверждён seeds 42/43/44; всего восемь обучений. Final test открыт после фиксации выбора. KL = 1 заранее задан как дополнительное сравнение.

Original final test	NDCG@10	Recall@10	Hybrid top-10
GPT-2	0.09121	0.14119	0.64693
Выбранная RL, KL = 0.1	0.08889	0.14153	**0.65979**
Дополнительная RL, KL = 1	0.09137	0.14146	0.64871
Недавние треки + популярность	**0.10026**	**0.15626**	0.65237

Выбранная RL: reward +1.99%, NDCG -2.55%. Интервал разницы NDCG [-0.004946; +0.000226] включает ноль - эквивалентность не доказана. Сильный KL: reward +0.28%, NDCG +0.18% по точечной оценке, также без подтверждённого прироста релевантности. Reward списка отличается от ожидаемого reward всей softmax-политики.

Без KL на validation NDCG упал на 61.85%, десять самых выдаваемых объектов заняли 72.91% top-10 выдачи против 7.34% baseline. Time reward вырос на 23.62%, но NDCG снизился на 11.51%, средняя длительность рекомендаций выросла с 191 до 246 секунд.

Смешивание RL с supervised CE проверено отдельной серией: три веса CE, ещё три контроля, по пять эпох. Все смешанные варианты потеряли 3.19-3.60% NDCG при допуске 1%; не приняты. Уменьшение sampled-повторов не компенсировало потерю релевантности.

4. Явный учёт повторов и контроль обучения

Сильный recent-items baseline указал на резерв качества. Добавлена смесь:

p = (1-g)*p_GPT2 + g*q_recent.

q суммирует exp(-lag/tau) по появлениям треков в истории. Lag измеряется событиями, включая UNK, не днями. Без известных объектов g = 0. Идея повторного потребления близка RepeatNet; его архитектура не воспроизводилась.

Шесть вариантов: глобальная/контекстная доля и tau 1/4/16. GPT-2 заморожена; gate обучается CE на всех 59 888 train-запросах. Выбран global-16: один обучаемый параметр, g = 0.1080394. Он прошёл development-пороги на seeds 42/43/44. Более сложный 161-параметровый gate уступил глобальному.

Новая группа: 1 000 пользователей вне двух прежних популяций, 5 000 запросов от 753 пользователей. Выбор смеси записан до прогнозов на этой группе.

Новая recency-популяция	NDCG@10	Recall@10
GPT-2	0.08190	0.12501
Недавние треки + популярность	0.09983	0.15547
GPT-2 + recency	**0.10133**	**0.15820**

Против GPT-2: NDCG +23.73%, Recall +26.55%; интервалы разниц [0.01559; 0.02333] и [0.02653; 0.04001] выше нуля. Против recent-items NDCG +1.51%, но интервал [-0.00246; 0.00545] включает ноль. Строгий критерий победы над обоими контролями не выполнен.

На 946 запросах со всеми целями в истории NDCG GPT-2 → смесь: 0.33027 → 0.45154. На остальных 4 054 запросах, с хотя бы одной новой для истории целью: 0.02394 → 0.01961. Усиление повторов ухудшило второй срез.

Нужна ли обученная доля

После открытия recency-популяции отдельно проверены заранее фиксированные доли при том же tau = 16:

Доля recency	Validation NDCG	Открытая recency-группа NDCG
Обученная, 10.804%	0.11571	0.10133
Фиксированная, 10%	0.11524	0.10018
Начальная sigmoid(-2), 11.920%	0.11658	0.10161

Это последующая диагностика, не независимый test. Фиксированная начальная доля дала не меньшую точечную оценку; полезность обучения доли не установлена. Основной наблюдаемый прирост связан с добавлением recency-механизма. Победитель задним числом не заменён; in-sample logits GPT-2 при обучении gate остаются ограничением.

5. История откликов улучшает MSE, но не выбор кандидата

Reward model расширена строго прошлыми наблюдавшимися откликами: средние доли пользователя, короткие окна, прошлые отклики на кандидата, число/давность появлений, длительность и сглаженный item prior. User ID не требуется. История откликов - последние 64 distinct user/T/item события, дубликаты усреднены; все события текущего T исключены. Для train item prior применяется leave-one-out, для последующих периодов - только ранний train.

Три рецепта: линейная поправка (17 параметров), MLP с embeddings (39 345), тот же MLP с 0.05 pairwise loss. Pair loss использует наблюдавшихся кандидатов одного user/T: 9 014 обучающих сравнений, без искусственных негативных меток. Максимум 12 эпох, patience 4, checkpoint по прежней selection MSE. Линейный вариант выбрал эпоху 12, оба MLP - эпоху 1.

Новая development-группа: 500 пользователей вне трёх прежних популяций; 5 000 запросов от 383 пользователей, 5 868 наблюдавшихся пар. Метки открыты после фиксации трёх checkpoint. Эта группа участвует в выборе рецепта и не является final test.

Метод	Development MSE	MAE	Query-macro pair accuracy, gap >= 0.10
Исходная raw reward model	0.20271	0.41452	42.83%
Прежний hybrid	0.19679	0.41915	42.83%
Средняя прошлых откликов пользователя	0.14341	0.30699	50.00%
История + линейная поправка	0.12557	0.28508	43.91%
История + MLP	**0.12524**	0.27921	44.20%
История + pairwise MLP	0.12840	**0.27703**	47.58%

Лучший MSE ниже hybrid на 36.36%, прошлого персонального среднего - на 12.67%. Интервал MSE-разницы MLP с персональной историей [-0.02192; -0.01446] ниже нуля. Это описательный development-результат; состав входной истории расширен, поэтому эффект не приписывается только архитектуре.

Для различения кандидатов доступны 1 863 сравнения из 120 запросов, 81 пользователь. Query-macro accuracy pairwise MLP 47.58% [39.48%; 55.34%]; сглаженный item prior 44.38%, простой prior прошлого отклика на кандидата 53.22%. Интервалы включают 50%; уверенное различение не установлено. При взвешивании пар, а не запросов, оценки меняются.

Решение по протоколу: ни одна модель не прошла порог query-macro accuracy 55%. Улучшение MSE и остальные проверки не заменяют этот критерий. RL на этих моделях не запущено. На этом этапе final reserve из 1 000 пользователей оставался закрытым; позже он использован только после допуска нового ранжировщика и фиксации RL-политики (разделы 7-8).

Интерпретация: модель лучше определяет общий стиль прослушивания пользователя. Но для ранжирования важна разница между кандидатами одной истории. Улучшение общей ошибки не гарантирует улучшения этой разницы.

6. Пять шагов, долгосрочная цель и воспроизведение

Rollout: общие 1 000 validation-историй, пять последовательных ID с добавлением в контекст. Рекомендация не означает фактическое прослушивание; будущим шагам не присваивались вымышленные наблюдавшиеся метки.

Политика, sampled	Уникальных из 5	Повтор предыдущего на шаге 5
GPT-2	4.253	16.6%
Исходная RL, KL = 0.1	4.024	25.2%
Исходная RL без KL	1.169	96.2%
GPT-2 + recency	4.121	17.1%

Greedy почти зацикливается уже у GPT-2: 1.027 уникального трека. Recency этот эффект не устраняет. Рост reward на синтетических историях не доказывает качества реальной последовательности.

Долгосрочная цель

Возможные метки: продолжение сессии в пределах 30 минут, возвращение от 24 часов до семи суток. Нулевая метка допустима лишь при полностью наблюдаемом будущем окне; примеры у правой границы данных цензурируются. Офлайн можно проверить предсказуемость, калибровку и устойчивость по времени/пользователям. Причинный вклад рекомендаций потребует данных показов и онлайн-проверки вместе с негативными реакциями/явной оценкой. Модель удержания здесь не обучалась.

Ограничения и аудит

Один источник, ограниченный каталог, высокая доля UNK и адаптивная validation. Новые популяции того же источника/периода не заменяют независимый датасет. Reward основан на наблюдавшихся прослушиваниях; отклик на произвольный новый показ неизвестен. Bootstrap не учитывает всю неопределённость обучения reward model. Включение нуля в интервал не доказывает эквивалентности.

Аудиты этих этапов повторили forwards, метрики, выбор, SHA, raw-подготовку когорт и response-историй; максимальные расхождения проверенных forwards - 0. Серия истории откликов: подготовка 5.34 с, три обучения с оценкой 37.49 с, аудит 16.78 с на Apple M4/MPS. Ресурсы расширения указаны в разделах 7-8. Автоматические тесты не добавлялись и не запускались.

Python 3.14.7; PyTorch 2.14.1, Transformers 5.19.0, NumPy 2.5.4, DuckDB 1.5.6. Расширение использует CatBoost 1.2.10 и отдельный requirements-ranking-lock.txt. Данные/веса локальны; агрегированные результаты и код опубликованы. Команды и версии кода по этапам - в README. Исторические аудиты требуют записанного source commit и соответствующих локальных артефактов. Подробные протоколы/результаты: RL, original test, смешанная цель, recency, история откликов, аудит истории откликов.

Итог первых этапов: RL выявил компромисс reward/релевантности и коллапс без KL. Учёт повторов улучшил baseline, история откликов - регрессию reward. Для продолжения потребовалось отдельно усилить выбор кандидатов; результат расширения приведён далее.

7. Парное обучение на расширенной выборке

Гипотеза: выбор checkpoint по MSE и малое число сравнений мешали научиться различать кандидатов. Сравнены MLP (3 201 параметр) и CatBoostRanker на одинаковых 16 числовых признаках, без user/item ID. Каталог и временные границы сохранены. Это совместная проверка объёма данных, цели и семейства моделей; вклад каждого изменения отдельно не доказан.

Prior по треку и глобальная средняя построены только до 12 000 000 секунд; обучение - после этой границы до 16 809 665. Используются наблюдавшиеся кандидаты одного user/T с разницей долей >= 0.10, максимум 64 пары на запрос. Суммарный вес каждого информативного запроса одинаков. При подготовке выбор запросов выполнен до чтения response-меток.

Train-выборка	Наблюдавшиеся строки	Сравнения после ограничения	Информативные запросы
Малая	18 630	1 743	427
Расширенная	148 472	46 373	9 881

Расширенная популяция: 3 000 выбранных пользователей, 2 462 с train-примерами; development и final исключены. MLP обучается pairwise logistic loss, CatBoost - PairLogit. Checkpoint выбирается по development query-macro accuracy, не MSE. На seed 42: малая MLP 50.45%, малый CatBoost 50.22%, расширенная MLP 53.17%, расширенный CatBoost 55.67%. Последний подтверждён seeds 43/44, выбран seed 42, 320 деревьев.

После выбора выполнена монотонная по score калибровка: sigmoid от нормированного score и logit средней прошлых откликов пользователя. Три параметра обучены на прежних 14 039 selection-парах; порядок кандидатов одного запроса сохраняется. Ranker score сам по себе не является вероятностью дослушивания.

Независимое подтверждение на новых пользователях

Отдельные 500 пользователей исключают training, все прошлые оценочные группы и final reserve. Открыты после выбора/калибровки: 20 000 запросов, 23 467 наблюдавшихся пар. Основной срез: 2 524 сравнения в 520 запросах от 173 пользователей. Accuracy усредняется сначала внутри запроса; равный score даёт 0.5.

Метод	Query-macro accuracy, gap >= 0.10	95% user-cluster интервал
Средняя по треку из раннего периода	49.22%	[45.46%; 53.13%]
Прошлые отклики на кандидата	53.52%	[51.20%; 56.07%]
Выбранный расширенный CatBoost	**58.42%**	**[54.69%; 62.14%]**

Парная разница с кандидатным контролем +4.90 п.п., интервал [+1.51; +8.19] п.п.; со средним по треку +9.20 п.п. [+4.55; +13.70]. Все критерии допуска к RL пройдены. Но calibrated MSE 0.141285 немного хуже кандидатного контроля 0.141186: преимущество в ранжировании не означает преимущества во всех метриках. Непрослушанные кандидаты и причинный отклик на новые показы здесь не проверены.

CatBoost 1.2.10 - последняя стабильная версия на дату запуска; PairLogit. Шесть обучений и оценка заняли 57.46 с на CPU; аудит 15.25 с. Проверены исходные истории, priors, checkpoints, калибровка и confirmation; максимальная разница forward 6.22e-15. Протокол, результат, подтверждение, ресурсы.

8. Повторный RL с подтверждённым reward

Reference - GPT-2 + recency: g = 0.1080394, tau = 16. CatBoost, калибровка и доля recency фиксированы; обучаются веса GPT-2. Цель - ожидаемый reward по каталогу минус KL между полными смесями и штраф соседнего повтора. Это одношаговое обучение без модели пользовательской среды.

Четыре рецепта KL 0.1/1 × штраф 0/0.1, по пять эпох на 4 000 train-контекстах. Validation-допуск: NDCG >= 99% reference, рост top-10 reward, ограничения охвата, концентрации и sampled-разнообразия. Выбран KL 0.1/штраф 0.1; проверки прошли seeds 42/43/44. Всего шесть обучений.

Финальный резерв открыт после фиксации выбора

5 000 запросов, 739 пользователей, 5 641 наблюдавшаяся цель. Популяция из 1 000 пользователей исключена из обучения reward и прежних оценочных групп. Другие RL-рецепты на reserve не оценивались; выбор после final не менялся.

Метод	NDCG@10	Recall@10	Calibrated top-10 reward
GPT-2 + recency reference	0.09570	0.15246	0.66548
Выбранная RL	0.09517	0.15100	0.66747
Недавние треки + популярность	0.09583	0.15416	0.67102

Reward +0.30%: разница +0.001991, 95% user-cluster интервал [+0.001837; +0.002156]. **NDCG -0.56%** по точечной оценке: разница -0.000536, интервал [-0.001896; +0.000810]. Нижняя граница хуже допустимых -0.000957 (1% reference). Сохранение качества в пределах 1% не подтверждено; **общий критерий RL не выполнен**. Это не доказательство потери более 1%. Преимущество над recent-items не установлено.

Пять объектов и ограничение повторов

На 1 000 validation-историях выполнено 16 greedy/sampled rollout. Policy получает добавленные ID; reward все пять шагов использует исходную историю реальных откликов. Синтетический выбор не обновляет response-статистику.

Sampled rollout	Уникальных из 5	Повтор предыдущего на шаге 5
Reference	4.121	17.1%
RL без штрафа, KL 0.1	4.055	20.4%
Выбранная RL	4.203	17.3%
Запрет соседнего повтора	4.737	0%

Штраф уменьшил повторы относительно RL без штрафа, но не reference. Greedy-зацикливание осталось: 1.038 уникального трека. Жёсткий запрет дал final NDCG 0.08166 (-14.68%): разнообразие не заменяет релевантность.

Серия заняла 127.74 с на Apple M4/MPS, аудит 47.88 с; peak memory footprint 2.70 GiB. Аудит воспроизвёл шесть политик, reward, 16 rollout, выбор и final; policy forward совпал точно, reward отличается < 3e-8. Протокол, результат, final, аудит.

Итог: ранжирование улучшено; общий критерий RL не пройден. Пользовательская польза не измерялась. Для независимого продолжения нужна новая выборка.