RL для музыкальных рекомендаций

Ислам / Islam-Y · 17 октября 2026
github.com/Islam-Y/RecSys-RL

Итоговый отчёт по заданию 2 T-Lab 2026. Исследование завершено 15 октября 2026; включена заключительная проверка на новых пользователях Yambda-500M.

1. Главные выводы

Обучены GPT-2 для следующего трека и модели вознаграждения, выполнено RL-дообучение. Проверены разные reward, KL, смешанная цель, учёт повторов, объём обучения, переранжирование и генерация пяти объектов.

Положительные результаты:

- Добавление истории повторного потребления к GPT-2 повысило NDCG@10 на 23.73% и Recall@10 на 26.55% на новой группе. Преимущество над простым recent-items контролем не подтверждено.
- Парный ранжировщик лучше различает наблюдавшихся кандидатов: accuracy 58.42% против 53.52% у кандидатного prior. Парная разница +4.90 п.п., 95% интервал [+1.51; +8.19]. Это отдельная метрика, не CTR или NDCG.
- Сохранение вероятностной массы shortlist улучшило sampled-генерацию на новых пользователях: 4.202 -> 4.426 уникального трека из пяти, соседние повторы 16.47% -> 7.67%. Оба изменения подтверждены парными интервалами.

Исследовательский вывод: прогнозируемый reward растёт без доказанного улучшения релевантности. В заключительной основной группе reward +2.73%, NDCG -0.80% по точечной оценке; сохранение NDCG в допуске 1% не подтверждено. Преимущество RL над сильными контролями, реальная удовлетворённость и удержание не установлены.

Требование задания	Что выполнено
GPT-2 baseline и reward model	Обучение с временным разбиением; оценка reward и простых контролей
RL и сравнение поведения	Обучение весов GPT-2; Recall/NDCG, reward, повторы, охват, концентрация и длительность
Анализ и воспроизведение	Разные цели/регуляризация, пять шагов, долгосрочные сигналы, протоколы, код и аудит

Допуск 1% - наш критерий поздних серий, а не требование задания. По условию содержательный отрицательный результат RL допустим. Разные серии относятся к разным группам; их абсолютные метрики нельзя сравнивать как последовательный рост качества.

2. Данные, baseline и защита от утечек

Источник - Yambda-50M, 46 467 212 listen-событий. Первая популяция - 1 000 пользователей по ранней активности; каталог - 2 000 наиболее частых train-треков. Границы: train до 19 983 235 секунд, validation до 23 121 935, test до 26 000 000.

Исходная выборка	Запросы	Пользователи	Цели
Train	59 888	961	68 451
Validation	5 000	734	5 840
Test	5 000	755	5 793

Контекст - BOS и до 64 listen-событий строго до T. Все события текущего user/T исключены; одновременные цели объединены в множество. История test включает реальные прошлые события без обновления весов. Вне каталога используется UNK: 61.77% train-контекста. Каталог покрывает 19.87% исходных test-прослушиваний; метрики условны на известный каталог.

GPT-2: случайная инициализация, ID-токены, 2 слоя, ширина 128, 4 головы, 661 504 параметра. Проверены три размера и восемь рецептов маленькой модели. Выбраны lr 0.0001, dropout 0.1, weight decay 0.01, seed 42, эпоха 26. Увеличение размера на этой постановке не дало основания заменить baseline.

Ранжируются все 2 000 объектов, без сэмплирования негативов. Recall@K - доля целей в выдаче, NDCG@K учитывает позиции; K=5/10/20, основной NDCG@10. Контроли: train-популярность, последние уникальные треки с дополнением популярными, ранее обученные политики.

Код, критерии и конфигурации новых серий фиксировались до запуска. Новые популяции исключали полные прежние группы. Test открывался после выбора; открытые группы не считались независимым подтверждением дальнейшей настройки. Validation была адаптивной и остаётся ограничением.

В заключительной проверке Yambda-500M исключены все 10 000 raw user ID исходного 50M. Для 64 общих пользователей точно совпали 338 211 событий. Это новые пользователи того же сервиса/периода, не другой домен.

Новая группа	Выбрано пользователей	Запросов / пользователей	Покрытие прослушиваний
Основная: >=50 ранних listen	5 000	50 000 / 4 141	19.99%
Дополнительная: 0-49	1 000	9 973 / 701	27.04%

Правило и веса заморожены до подготовки этих групп. Основная определяет решение; дополнительная её не заменяет. Протокол, ревизия, размер и SHA источника.

3. Reward: регрессия и выбор кандидата

Метка - среднее min(played_ratio_pct,100)/100 по наблюдавшимся дубликатам user/T/item. Нули сохраняются; непрослушанные кандидаты не получают вымышленные нули. Доля прослушивания - косвенный сигнал интереса, не измерение удовлетворённости.

Исходная embeddings/MLP: 202 593 параметра, история, кандидат, user ID, длительность и повторы. Reward train - 54 412 наблюдавшихся пар, поздняя selection - 14 039. На исходном test MSE raw 0.18133, фиксированной hybrid-калибровки 0.17121, персонального среднего 0.17564. Hybrid лучше по MSE, но хуже по MAE: 0.36546 против 0.35590. Общая ошибка не доказывает правильного порядка кандидатов.

Добавление прошлых откликов снизило development MSE с 0.19679 у прежнего hybrid до 0.12524 у MLP. Однако лучший парный вариант получил accuracy 47.58% [39.48%; 55.34%] и не прошёл заранее заданный порог 55%. RL на этих моделях не запускалось. Это development-результат, не независимая победа.

Ранжировщик с независимой проверкой

Сравнены числовая MLP и CatBoostRanker на одних 16 признаках: прошлые доли пользователя/кандидата, короткие окна, сглаженный item prior, частота/давность, UNK и длительность. User/item ID как признаки отсутствуют. История - до 64 distinct user/T/item строго до T; дубликаты усреднены.

Prior построен до 12 000 000 секунд, ranker обучен после этой границы до 16 809 665. Сравнений стало 1 743 -> 46 373, информативных запросов 427 -> 9 881. Кандидаты реально наблюдались в одном user/T; разрыв меток >=0.10, максимум 64 пары на запрос, равный вес информативных запросов.

Выбран CatBoost 1.2.10, PairLogit, 320 деревьев; рецепт подтверждён seeds 42/43/44 на development. После выбора обучена sigmoid-калибровка по score и прошлой средней пользователя на прежних 14 039 selection-парах; порядок кандидатов одного запроса сохраняется. Семейство, объём данных и цель менялись совместно; отдельный вклад не изолирован.

Независимая confirmation	Query-macro accuracy	95% интервал
Ранний item prior	49.22%	[45.46%; 53.13%]
Прошлые отклики на кандидата	53.52%	[51.20%; 56.07%]
Выбранный CatBoost	**58.42%**	**[54.69%; 62.14%]**

Поддержка: 2 524 сравнения в 520 запросах от 173 пользователей; оценочная популяция 500 пользователей. Парная разница с кандидатным контролем **+4.90 п.п. [+1.51; +8.19]**. Допуск к RL пройден. Но MSE 0.141285 немного хуже кандидатного prior 0.141186; отклик на непоказанные объекты неизвестен. Результат, настройки, PairLogit.

4. RL: рост прокси и цена для релевантности

Использован одношаговый контекстный бандит с фиксированной reward model. Обучаются веса GPT-2; точная сумма по небольшому каталогу даёт градиент ожидаемого reward. Реальные переходы пользователя и многошаговый return не обучаются.

```
J(h) = sum_i pi(i|h)*r_hat(h,i) - beta*KL(pi(.|h)||pi_ref(.|h))
```

В таблицах top-10 reward - средний прогноз десяти выданных объектов с равными весами позиций. Он отличается от ожидания reward полной политики в функции обучения.

Исходная RL: пять эпох на 4 000 поздних train-контекстах, AdamW lr 0.00005, batch 64, clip 1, dropout выключен. Проверены raw/hybrid/time reward и KL. Raw/KL 0.1 выбран на validation при NDCG >=95% reference и подтверждён seeds 42/43/44; KL 1 заранее задан дополнительным контролем. В поздних сериях допуск ужесточён до 1%.

Исходный test, 5 000 запросов	NDCG@10	Recall@10	Hybrid top-10
GPT-2	0.09121	0.14119	0.64693
Выбранная RL, KL 0.1	0.08889	0.14153	0.65979
Дополнительная RL, KL 1	0.09137	0.14146	0.64871
Недавние треки + популярность	0.10026	0.15626	0.65237

Выбранная RL: reward +1.99%, NDCG -2.55% по точечной оценке; CI NDCG-разницы [-0.004946; +0.000226]. Отсутствие значимого снижения не доказывает эквивалентность. Hybrid имеет вид 0.3565745*raw + constant(user): улучшает калибровку, но не меняет порядок кандидатов одной истории.

Без KL validation NDCG упал на 61.85%, десять самых выдаваемых треков заняли 72.91% top-10. Time reward вырос на 23.62%, NDCG снизился на 11.51%, длительность выдачи выросла с 191 до 246 с. Смешанная RL/CE снизила NDCG на 3.19-3.60% и не прошла допуск 1%.

Повторная RL с новым reward

Reference улучшен смесью (1-g)*p_GPT2 + g*q_recent, g=0.1080394, tau=16 событий. q_recent суммирует exp(-lag/tau) по появлениям трека; lag измеряется событиями, не днями. На новой recency-группе смесь повысила NDCG на 23.73% против GPT-2; превосходство над recent-items и польза обучения g отдельно не установлены. Дальнейшие RL сравниваются с этой смесью.

Новые оценочные группы	Reward против reference	NDCG против reference	Допуск 1%
RL, 4 000 train-контекстов; 5 000 final-запросов	+0.30%	-0.56%	Не подтверждён
RL, 11 977 train-контекстов; 20 000 final-запросов	+0.35%	-0.73%	Не подтверждён

CatBoost и recency фиксированы, KL считается по полной смеси; добавлен штраф соседнего повтора 0.1. Пять эпох, KL 0.1/1, выбранные рецепты подтверждены тремя training seeds. Расширение одновременно увеличило число контекстов и optimizer steps. Проверенный компромисс не достиг критерия; это не доказательство бесполезности дополнительных данных. Исходный test, повторная RL, расширенная RL.

5. Shortlist: правило применения reward

Переранжирование проверено отдельно от RL-обучения. Усечение оставляет top-M и заново нормирует вероятности. В development top-50/top-100 содержали 49.21%/61.02% массы reference. Даже alpha 0 сохранял статический top-20, но снижал sampled-уникальность с 4.219 до 3.351/3.627. Все ненулевые усечённые правила нарушили допуск уникальности и не были выбраны для final.

Проверенная гипотеза: менять порядок внутри shortlist, сохраняя вероятность остального каталога. Для S=top-M и z=sum_S p_ref:

```
score_i = log(p_ref_i) + alpha*(r_hat_i - lambda*I(i=last))
p_i = z*softmax_S(score)_i для i в S
p_i = p_ref_i для i вне S
```

Полный каталог сортируется заново. В development среди десяти ненулевых вариантов выбраны M = 100, alpha = 16, lambda = 0.1. Нулевые правила точно воспроизвели reference. На оставшихся 1 738 пользователях 50M reward +3.06%, sampled-уникальность +0.210, повторы -7.5 п.п.; NDCG noninferiority не подтверждена. Положительный описательный срез 110 ранне-активных пользователей не изменил параметры.

Заключительная проверка без обучения и подбора

На новых пользователях 500M оставлены те же каталог, веса, правило и границы времени. Семь заранее заданных методов, 50 000 основных запросов от 4 141 пользователя:

Основная группа	NDCG@10	Recall@10	Calibrated top-10 reward
GPT-2 + recency reference	0.101423	0.157985	0.643694
Сохранение массы	0.100613	0.158084	0.661298
Усечение, те же M/alpha	0.100788	0.158565	0.661406
Историческая RL	0.100778	0.158072	0.645719
Расширенная RL	0.101043	0.158189	0.645890
Train-популярность	0.011399	0.025280	0.640946
Недавние треки + популярность	0.102080	0.158428	0.649590

Reward **+2.73%**, разница +0.017604, 95% CI [+0.017131; +0.018101]. NDCG **-0.80%** по точечной оценке: -0.000809, CI [-0.002043; +0.000336]. Нижняя граница хуже допустимых -0.001014, поэтому **общий критерий не выполнен**. Это не доказательство потери более 1%; снижение тоже не установлено. Recall CI включает ноль. Прежний положительный срез активных пользователей не подтвердился на новой основной группе.

Критерий: положительный reward CI, NDCG noninferiority и точечные sampled-допуски одновременно: уникальность >=reference-0.05, соседний повтор <=reference+1 п.п. Пороги после оценки не менялись. Правило - постобработка фиксированной политики; результат не объявляется победой RL. Полный результат, протокол.

6. Пять шагов и изменение генерации

На каждой новой группе выбраны 1 000 общих запросов: 772 основных и 377 дополнительных query-пользователей. Reference, выбранное правило и matched truncated проверены в greedy и sampled seeds 42/43/44: всего 24 запуска генерации. Sampling seeds меняют действия, исходные контексты одинаковы.

Policy получает синтетические ID, а reward использует исходную наблюдавшуюся response-историю на всех пяти шагах. Сгенерированный трек не считается реальным прослушиванием и не создаёт вымышленную метку отклика. Метрики sampled усредняются по трём траекториям запроса.

Группа / sampled-метод	Уникальных из пяти	Соседний повтор на шаге 5
Основная / reference	4.202	16.47%
Основная / сохранение массы	**4.426**	**7.67%**
Основная / усечение	3.988	13.70%
Дополнительная / reference	4.278	14.40%
Дополнительная / сохранение массы	**4.465**	**7.20%**
Дополнительная / усечение	4.044	13.83%

Основная против reference: уникальность +0.224, 95% CI [+0.185; +0.267]; повторы -8.80 п.п. [-10.18; -7.44]. Против усечения: +0.438 уникального [+0.402; +0.477], -6.03 п.п. повторов [-7.22; -4.80].

Дополнительная против reference: +0.187 уникального [+0.150; +0.228], -7.20 п.п. повторов [-8.69; -5.80]. Парные интервалы исключают ноль. Это номинальные user-cluster интервалы для фиксированных моделей/трёх sampling seeds, без всей неопределённости reward-обучения.

Что осталось нерешённым

Greedy почти зацикливается: основная reference -> правило, 1.010 -> 1.267 уникального, соседние повторы 100% -> 85.4%; дополнительная 1.007 -> 1.303 и 100% -> 82.5%. Greedy-результаты сохранения массы и усечения совпали. На основной группе статический NDCG сохранения массы чуть ниже усечения: -0.000175, CI [-0.000257; -0.000103].

В основной top-10 доля знакомых объектов выросла 50.87% -> 56.35%, длительность снизилась 190.3 -> 180.9 с, доля десяти самых выдаваемых треков выросла 6.33% -> 7.29%. Меньше соседних повторов не означает меньше повторного потребления или отсутствие смещения прокси к короткому контенту.

Дополнительная группа, 9 973 запроса: reward +3.01%, NDCG -0.97%, CI NDCG [-0.004229; +0.002108]; допуск также не подтверждён. Reward MSE хуже кандидатного prior на обеих группах: 0.138820 против 0.138572 и 0.128680 против 0.128043. Улучшение генерации не доказывает улучшения рекомендаций в целом.

7. Ответы на исследовательские вопросы

Как RL меняет поведение? Повышает оптимизируемый прогноз; без KL концентрируется на малом наборе треков. Регуляризация сдерживает изменение распределения, но не устраняет ошибки reward. Выбор цели меняет длительность и повторное потребление; высокий reward сам по себе не критерий полезности.

Сохраняется ли релевантность? В поздних независимых проверках сохранение NDCG в допуске 1% не установлено. Интервал с нулём не доказывает эквивалентность, неудача noninferiority не доказывает потерю более 1%. Recent-items остаётся обязательным контролем; сравнения только с популярностью было бы недостаточно.

Что дают пять шагов? Выявляют зацикливание и разницу greedy/sampling. Сохранение массы уменьшает концентрацию sampled-генерации. Однако синтетические ID уводят контекст от реальной истории; это не моделирует решение пользователя послушать или уйти.

Каков компромисс? Рост прогноза reward может сопровождаться ухудшением порядка релевантных целей. Низкая MSE не гарантирует правильного выбора кандидата; потребовалась отдельная парная проверка. Одно число не заменяет релевантность, повторы, новизну и реальные негативные реакции.

Как приблизиться к долгосрочной цели

Продуктовая цель - удовлетворённость и желание вернуться. Возможные отдельные сигналы: продолжение сессии в течение 30 минут, возврат от 24 часов до семи суток, явная оценка и негативные реакции. Примеры у правой границы данных цензурируются; отсутствие возврата можно считать нулём лишь при полностью наблюдаемом будущем окне.

Возможная гипотеза reward: w1*I(session_continues) + w2*I(return_7d) - w3*I(explicit_negative). Веса требуют продуктового выбора; такой reward здесь не обучался.

Офлайн можно проверить предсказуемость и калибровку меток на более позднем периоде. Возврат зависит от привычек, поэтому хороший прогноз не установит причинного вклада рекомендации. Нужны данные показов, пропусков и позиций, затем контролируемая онлайн-проверка с удовлетворённостью, негативными реакциями и возвращаемостью. Модель удержания и онлайн-эксперимент здесь не выполнялись.

Границы вывода

- Каталог ограничен; UNK в новых основных контекстах 68.63%. Оценка не охватывает полный каталог.
- Прослушивания не дают наблюдаемого отклика на каждый произвольный показ. Модель может эксплуатировать ошибки вне обучающей поддержки.
- Новые пользователи 500M принадлежат тому же сервису/периоду. Независимость пользователей не равна независимости домена.
- Validation адаптивна. Новые проверочные группы не подбирали настройки, но не устраняют все ограничения разработки.
- Bootstrap группирует запросы по пользователям, 2 000 повторов; основным ranking-метрикам дан равный вес запросов. Не покрыта вся неопределённость обучения и онлайн-эффектов.

Итог: получены работающий RL-эксперимент, подтверждённый ранжирующий сигнал и воспроизводимое улучшение sampled-генерации. Общий критерий качества и реальная пользовательская польза не подтверждены. Экспериментальная часть завершена без подбора новых параметров по заключительной оценке.

8. Артефакты, аудит и воспроизведение

Репозиторий содержит исходники, конфигурации, протоколы и агрегированные JSON. Последовательность решений и неудачных гипотез - в журнале. README даёт краткий итог; воспроизведение объясняет зависимости, исходные запуски и аудит по версиям.

Среда измерений: Python 3.14.7, PyTorch 2.14.1, Transformers 5.19.0, NumPy 2.5.4, DuckDB 1.5.6, CatBoost 1.2.10; Apple M4/MPS, ranking на CPU. Версии закреплены в requirements-lock.txt и requirements-ranking-lock.txt. Это описание выполненной среды, не рекомендация последних версий.

Raw, checkpoints и промежуточные прогнозы локальны. Клон без них позволяет изучить результаты/код, но не запускает аудит весов. Manifest содержит пути/SHA; перенос требует корректной подготовки, отчёты не заменяют модели. Полное повторение - отдельный клон, пустые каталоги и собственные результаты каждого этапа.

Этап	Код для аудита	Результат / свидетельство
Исходная RL и test	c97ac8f	Final result
GPT-2 + recency	5c8158e	Новая группа
Парный ranker	669bec6	Confirmation
RL с новым reward	3de7c53	Final reserve
Shortlist и объём RL	2de9051	Результат
Сохранение массы	de11aa4	Результат
Новые пользователи 500M	5081646	Результат, аудит

Исторический аудит требует указанной версии исходников и соответствующих локальных артефактов. Новые Python-модули меняют полный source SHA. Для последней серии:

```
source .venv/bin/activate
python -m recsys_rl.transfer_experiment --device auto --audit
```

Последний аудит воспроизвёл обе когорты/raw-истории, 12 блоков, три фиксированные policy и reward, прямые прогнозы 68 932 наблюдавшихся целей, сохранение массы, 24 запуска генерации, метрики и интервалы. Разница повторных forward 0; прямого reward и кэша <3e-8. Автоматические тесты в рамках исследования не добавлялись и не запускались.

Подготовка 22.99 с, оценка 242.43 с, аудит 203.61 с; peak memory footprint оценки 2.84 GiB, аудита 3.08 GiB. Скачивание не включено. Это локальная оценка, не производственная пропускная способность. Новые группы теперь открыты и не подходят для независимого подтверждения дальнейшего подбора.

Задание, хронология экспериментов и машинно-читаемые результаты доступны в репозитории. Внешние источники: описание Yambda авторами, карточка данных, PairLogit. Числа и интервалы отчёта взяты из нашего эксперимента, а не из опубликованных бенчмарков Yambda.